

# Numerical Computation of Eigenvalues

## Theoretical Background

(S)cientific (C)omputing (T)eam II-2014  
ILI-286 DI-UTFSM Chile

August 26, 2014

# Table of contents

- 1 Definición
- 2 Computación
- 3 Algoritmos Matriciales
- 4 Ritz Values

# Valores Propios

## Definición

### Definición

Sea  $A$  una matriz cuadrada en  $\mathbb{R}^{n \times n}$ .

Diremos que  $\lambda \in \mathbb{C}$  y  $\vec{v} \in \mathbb{C}^{n \times 1}$  son valor y vector propios si:

$$A\vec{v} = \lambda\vec{v} \text{ y } \vec{v} \neq \vec{0}$$

¿Cómo podemos organizar todos los valores propios?

Sea  $A$  una matriz cuadrada en  $\mathbb{R}^{n \times n}$ . Diremos que  $\lambda_i \in \mathbb{C}$  y  $\vec{v}_i \in \mathbb{C}^{n \times 1}$  son el  $i$ -ésimo valor y vector propio. Si ahora los sumamos todos y los ordenamos considerando que el sub índice  $i$  corresponde a la  $i$ -ésima columna, obtenemos (Hint:  $A\vec{v}_i = \lambda_i\vec{v}_i = \vec{v}_i\lambda_i$ ):

# Valores Propios

## Representación Matricial

¿Cómo podemos organizar todos los valores propios?

Sea  $A$  una matriz cuadrada en  $\mathbb{R}^{n \times n}$ . Diremos que  $\lambda_i \in \mathbb{C}$  y  $\vec{v}_i \in \mathbb{C}^{n \times 1}$  son el  $i$ -ésimo valor y vector propio. Si ahora los sumamos todos y los ordenamos considerando que el sub índice  $i$  corresponde a la  $i$ -ésima columna, obtenemos (Hint:  $A\vec{v}_i = \lambda_i\vec{v}_i = \vec{v}_i\lambda_i$ ):

$$A \begin{bmatrix} v_1 & v_2 & \dots & v_n \end{bmatrix} = \begin{bmatrix} v_1 & v_2 & \dots & v_n \end{bmatrix} \begin{bmatrix} \lambda_1 & 0 & \dots & 0 \\ 0 & \lambda_2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \lambda_n \end{bmatrix}$$

$$A V = V \Lambda$$

# Valores Propios

## Representación Matricial

Cómo podemos organizar todos los valores propios?

Sea  $A$  una matriz cuadrada en  $\mathbb{R}^{n \times n}$ . Diremos que  $\lambda_i \in \mathbb{C}$  y  $\vec{v}_i \in \mathbb{C}^{n \times 1}$  son el  $i$ -ésimo valor y vector propio. Si ahora los sumamos todos y los ordenamos considerando que el sub índice  $i$  corresponde a la  $i$ -ésima columna, obtenemos (Hint:  $A\vec{v}_i = \lambda_i\vec{v}_i = \vec{v}_i\lambda_i$ ):

$$A V = V \Lambda$$

Si  $V^{-1}$  existe, se tiene:

$$A = V \Lambda V^{-1}$$

# Valores Propios

## Potencias de $A$

Dado  $A = V \Lambda V^{-1}$ , ¿Qué podemos decir de  $A^n$ ?

$$\begin{aligned} A^n &= (V \Lambda V^{-1})^n \\ &= V \Lambda V^{-1} V \Lambda V^{-1} \dots V \Lambda V^{-1} \end{aligned}$$

¿Podemos simplificar algo?

$$A^n = V \Lambda^n V^{-1}$$

¡Excelente!

# Valores Propios

## Otra definición

### Un valor propio dominante...

Sea  $A$  una matriz cuadrada en  $\mathbb{R}^{n \times n}$ . Un *valor propio dominante* de  $A$  es un valor propio  $\lambda$  de magnitud  $(|\lambda|)$  mayor a todos los otros valores propios. Si existiera, el vector propio  $\vec{v}$  asociado a  $\lambda$  es llamado vector propio dominante.

# Valores Propios

## Primer Algoritmo

Un valor propio dominante...se encuentra así

---

### Algorithm 1 Power Iteration

---

- 1:  $\vec{x}_0$ =Dato inicial
  - 2: **for**  $j = 0$  to  $\infty$  **do**
  - 3:    $\vec{u}_{j-1} = \vec{x}_{j-1} / \|\vec{x}_{j-1}\|_2$
  - 4:    $\vec{x}_j = A \vec{u}_{j-1}$
  - 5:    $\lambda_j = \vec{u}_{j-1}^T A \vec{u}_{j-1}$
  - 6: **end for**
  - 7:  $\vec{u}_j = \vec{x}_j / \|\vec{x}_j\|_2$
-



# Valores Propios

## Convergencia de Power Iteration

Th: Sea  $A$  una matriz de  $n \times n$  con valores propios  $\lambda_1, \dots, \lambda_n$ , y  $|\lambda_1| > |\lambda_2| \geq |\lambda_3| \geq \dots \geq |\lambda_n|$ . Asuma que los vectores propios forman una base de  $\mathbb{R}^n$ . Para casi todo vector inicial, Power Iteration converge *linealmente* al vector propio asociado a  $\lambda_1$  con tasa de convergencia  $S = |\lambda_2/\lambda_1| < 1$ .

# Valores Propios

## Demostración

Sea  $\vec{v}_1, \vec{v}_2, \dots, \vec{v}_n$  una base de  $\mathbb{R}^n$  y  $\lambda_1, \dots, \lambda_n$  los valores propios de  $A$  con  $\vec{v}_1, \vec{v}_2, \dots, \vec{v}_n$  los vectores propios asociados a cada valor propio.

Dado que  $\vec{v}_i$  forman una base de  $\mathbb{R}^n$ , podemos escribir cualquier vector en  $\mathbb{R}^n$  como:

$$\vec{x}_0 = \sum_{i=1}^n c_i \vec{v}_i = V \vec{c}.$$

Además considere que  $c_1 \neq 0$  y  $c_2 \neq 0$ . Aplicando el Power Iteration y recordando que  $AV = V\Lambda$  obtenemos:

$$\vec{x}_0 = V \vec{c}$$

$$A \vec{x}_0 = A V \vec{c} = V \Lambda \vec{c}$$

$$A^2 \vec{x}_0 = A V \Lambda \vec{c} = V \Lambda^2 \vec{c}$$

$$\vdots$$

$$A^k \vec{x}_0 = V \Lambda^k \vec{c}$$

# Valores Propios

## Demostración - Continuación

Si normalizamos en cada iteración obtenemos:

$$\begin{aligned}\frac{A^k \vec{x}_0}{\lambda_1^k} &= \frac{V \Lambda^k \vec{c}}{\lambda_1^k} \\ &= \sum_{i=1}^n c_i \left( \frac{\lambda_i}{\lambda_1} \right)^k \vec{v}_i\end{aligned}$$

Donde obtenemos  $\left( \frac{\lambda_i}{\lambda_1} \right)^k \rightarrow 0$  como  $k \rightarrow \infty$  para  $i \geq 2$ .

# Valores Propios

¿Y de que sirve esto?

## Conclusión Power Iteration

- Ahora tenemos un algoritmo para encontrar  $e$ / valor propio dominante.
- ¿Y si quiero encontrar otro?
- Este algoritmo no sirve. O si...
- Pensemos....
- Aplicaciones: “PCA, Page-Rank, Graph Theory, Google, Facebook, Netflix, ...”

# Valores Propios

¡Otra definición!

## Más propiedades de valores propios

Th: Sea  $\lambda_1, \dots, \lambda_n$  los valores propios de  $A$ .

- (a) Los valores propios de la matriz inversa  $A^{-1}$  son  $\lambda_1^{-1}, \dots, \lambda_n^{-1}$ ,  
asumiendo que  $A^{-1}$  existe.
- (b) Los valores propios de la matriz  $A - sI$  son:  $\lambda_1 - s, \dots, \lambda_n - s$ .

En ambos casos los vectores son los mismo. La demostración de estas propiedades se vieron anteriormente.

# Valores Propios

## Flashback

¿Y que ocurre si utilizamos el Power Iteration con la matriz inversa?

- ¿Se puede?
- No creo....
- Veamos.

# Valores Propios

Utilizando  $A^{-1}$  donde aparece  $A$  y considerando

$$|\lambda_1| > |\lambda_2| \geq |\lambda_3| \geq \dots > |\lambda_n|$$

---

```

1:  $\vec{x}_0$ =Dato inicial
2: for  $j = 0$  to  $\infty$  do
3:    $\vec{u}_{j-1} = \vec{x}_{j-1} / \|\vec{x}_{j-1}\|_2$ 
4:    $\vec{x}_j = A^{-1} \vec{u}_{j-1}$ 
5:    $\lambda_j = \vec{u}_{j-1}^T A^{-1} \vec{u}_{j-1}$ 
6: end for
7:  $\vec{u}_j = \vec{x}_j / \|\vec{x}_j\|_2$ 

```

---

Obviando los pasos, podemos concluir que obtenemos  $\lambda_n^{-1}$  y  $\vec{v}_n$ . Una sustitución interesante es reemplazar la línea 5 por  $\lambda_j = \vec{u}_{j-1}^T \vec{x}_j$

# Valores Propios

¡Aprovechando el momentum!

Utilizando  $A - sI$  donde aparece  $A$  y considerando

$$|\lambda_1| > |\lambda_2| > |\lambda_3| > \dots > |\lambda_n|$$

---

```

1:  $\vec{x}_0$ =Dato inicial
2: for  $j = 0$  to  $\infty$  do
3:    $\vec{u}_{j-1} = \vec{x}_{j-1} / \|\vec{x}_{j-1}\|_2$ 
4:    $\vec{x}_j = (A - sI)^{-1} \vec{u}_{j-1}$ 
5:    $\lambda_j = \vec{u}_{j-1}^T \vec{x}_j$ 
6: end for
7:  $\vec{u}_j = \vec{x}_j / \|\vec{x}_j\|_2$ 

```

---

Obviando los pasos, podemos concluir que obtenemos  $\tilde{\lambda}$  y  $\tilde{\vec{v}}$ .



# Valores Propios

¿Qué es  $\tilde{\lambda}$ ? No entiendo...

- Anteriormente dijimos que la aplicación del algoritmo Power Iteration a la matriz  $A$  encontraba el valor propio dominante  $\lambda_1$  de esta.
- OK, ya se eso.
- ¿Que ocurre si aplicamos el Power Iteration a la matriz  $A^{-1}$ ?
- Encontramos  $\lambda_n^{-1}$  dado que  $\lambda_n^{-1}$  es el *valor propio dominante* de  $A^{-1}$ . :-)
- ¿Y?
- mmmm, pensemos.
- Si aplicamos el algoritmo Power Iteration a  $(A - sI)^{-1}$  encontramos ... ¡El valor propio dominante de  $(A - sI)^{-1}$ !

# Valores Propios

¿Qué es  $\tilde{\lambda}^{-1}$ ? No entiendo...

- Si aplicamos el algoritmo Power Iteration a  $(A - sI)^{-1}$  encontramos ... ¡El valor propio dominante de  $(A - sI)^{-1}$ !
- OK, entonces  $\tilde{\lambda}$  es el valor propio dominante de  $(A - sI)^{-1}$ .
- ¿Es  $\tilde{\lambda}$  un valor propio de  $A$ ?
- No
- Pff, ¿Y de que me sirve?
- ¡De mucho! Con  $\tilde{\lambda}$  podemos encontrar un valor propio diferente al valor propio dominante o el de menor magnitud (en el caso de usar  $A^{-1}$ ).
- ¿Cómo?
- $\tilde{\lambda} = (\lambda_i - s)^{-1}$ . Simplificando:  $\lambda_i = \tilde{\lambda}^{-1} + s$ .

# Valores Propios

## Segundo Algoritmo

Un valor propio *no* dominante...se encuentra así

---

### Algorithm 2 Inverse Power Iteration

---

- 1:  $\vec{x}_0$ =Dato inicial
  - 2: **for**  $j = 0$  to  $\infty$  **do**
  - 3:    $\vec{u}_{j-1} = \vec{x}_{j-1} / \|\vec{x}_{j-1}\|_2$
  - 4:    $\vec{x}_j = (A - sI)^{-1} \vec{u}_{j-1}$
  - 5:    $\lambda_j = \vec{u}_{j-1}^T \vec{x}_j$
  - 6: **end for**
  - 7:  $\vec{u}_j = \vec{x}_j / \|\vec{x}_j\|_2$
- 

Este algoritmo encuentra  $\lambda_i = \tilde{\lambda}^{-1} + s$ . Donde  $\lambda_i$  es el valor propio más cercano a  $s$ .

# Valores Propios

## Tercer Algoritmo

### Otro algoritmo — Rayleigh Quotient Iteration

---

#### Algorithm 3 Rayleigh Quotient Iteration

---

- 1:  $\vec{x}_0$ =Dato inicial
  - 2: **for**  $j = 1$  to  $\infty$  **do**
  - 3:    $\vec{u}_{j-1} = \vec{x}_{j-1} / \|\vec{x}_{j-1}\|_2$
  - 4:    $\lambda_{j-1} = \vec{u}_{j-1}^T \mathbf{A} \vec{u}_{j-1}$
  - 5:   Solve  $(\mathbf{A} - \lambda_{j-1} \mathbf{I}) \vec{x}_j = \vec{u}_{j-1}$
  - 6: **end for**
  - 7:  $\vec{u}_j = \vec{x}_j / \|\vec{x}_j\|_2$
- 

(Para valores propios no repetidos) Este algoritmo encuentra el valor propio dominante  $\lambda_i$  y converge cuadráticamente. ¡Si la matriz es simétrica converge cúbicamente!.

# Valores Propios

Uff, hemos visto muchas cosas...

## Conclusiones

- Power Iteration: Valor propio dominante
- Inverse Power Iteration: Valor propio más cercano a  $s$ .
- Rayleigh Quotient Iteration: Depende de la condición inicial y converge cuadráticamente.
- Rayleigh Quotient Iteration: (Precaución línea 5) ¡Resolver  $(A - \lambda_{j-1} I) \vec{x}_j = \vec{u}_{j-1}$  únicamente si la matriz no es singular!
- ¿Qué hago si la matriz  $(A - \lambda_{j-1} I)$  es singular?
- Detener el algoritmo, ¡ya se convergió! :-)
- Esto es como jugar con fuego ... ¡pero sin quemarse!

# Valores Propios

Sigamos...

## ¿Recuerda?

Si  $A$  tiene valor propio  $\lambda$  y vector propio  $\vec{v}$   
entonces  $B = Q^{-1}AQ$ , tiene valor propio  $\lambda$  y vector propio  $Q^{-1}\vec{v}$ .

En este caso se dice que  $A$  es *una matriz similar* a  $B$ .

## Theorem

Matrices Similares tienen los mismos valores propios.

Otra Demostración:

$$\begin{aligned}\det(B - \lambda I) &= \det(Q^{-1}AQ - \lambda I) \\ &= \det(Q^{-1}AQ - \lambda Q^{-1}IQ) \\ &= \det(Q^{-1}(A - \lambda I)Q) = \det(Q^{-1})\det(A - \lambda I)\det(Q) \\ &= \det(A - \lambda I)\end{aligned}$$

# Valores Propios

Algoritmos matriciales para encontrar todos los valores propios al mismo tiempo

## Normalized Simultaneous Iteration

---

```
1:  $\bar{Q}_0 = I$   
2: for  $j = 0$  to  $\infty$  do  
3:    $A \bar{Q}_j = \bar{Q}_{j+1} R_{j+1}$   
4: end for  
5:  $\Lambda = \bar{Q}^T A \bar{Q}$ 
```

---

# Valores Propios

Algoritmos matriciales para encontrar todos los valores propios al mismo tiempo

## Unshifted QR algorithm

---



---

```

1:  $Q_0 = I$ 
2:  $R_0 = A$ 
3:  $\bar{Q} = Q_0$ 
4: for  $j = 0$  to  $\infty$  do
5:    $\underline{Q}_{j+1} R_{j+1} = qr(R_j Q_j)$ 
6:    $\bar{Q} = \bar{Q} Q_j$ 
7: end for
8:  $\Lambda = \text{diag}(R Q)$ 

```

---

Recuerde que  $A = QR \Rightarrow Q^T A Q = R Q$ , i.e.  $A$  es similar a  $R Q$ .  
 ¡En este caso tenemos una secuencia de transformaciones similares!



# Valores Propios

Por último, Ritz values...

## ¿Qué son los Ritz values?

- Son una *estimación* de los valores propios.
- ¿Cómo se obtienen?
- Se obtienen de la matriz  $H_n$  de la iteración de Arnoldi en GMRes.
- ¿Qué es  $H_n$ ? En GMRes se construye  $\tilde{H}_n$ .
- $H_n = Q_n^* Q_{n+1} \tilde{H}_n$ , i.e. removiendo la última fila de  $\tilde{H}_n$ .
- Ahora tengo una matriz más pequeña, ¿Cómo la uso?
- Se obtienen los valores propios de esta (¡Estos son los Ritz Values!) a través de los métodos ya discutidos :-)
- ¿Puedo hacer shifts y el resto de cosas que aprendí? ¡Sí!

# Valores Propios

## ¿Algo más?

- Sí
- ¿Que cosa?
- Les sugiero encarecidamente que busquen en el libro un ejemplo de cada método y lo hagan a mano en lo posible.
- OK, ¿Algo más?
- Sí
- Uff, ¿No será mucho?
- No. Implementen todos los métodos y traigan sus códigos a clases en su computador personal.
- OK, that's easy.
- Excellent. Now, we will do our presentations and videos in English. It is good for all of us! Good job.